

TUGAS AKHIR MATA KULIAH DATA MINING
LAPORAN PENELITIAN



Klasifikasi Churn Nasabah Menggunakan Algoritma Decision Tree C4.5
pada Dataset Bank Customer Churn

DISUSUN OLEH :
KELOMPOK A12

Iklina Najzil Muhsinina 242410101001

Neva Maritza Andini 242410101021

Najwa Khuril Asna 242410101053

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS ILMU KOMPUTER
UNIVERSITAS JEMBER

2025

DAFTAR ISI

DAFTAR ISI.....	2
BAB 1. Pendahuluan.....	3
1.1 Judul Penelitian.....	3
1.2 Latar Belakang.....	3
1.3 Rumusan Masalah.....	5
1.4 Batasan Masalah.....	5
1.5 Tujuan Penelitian.....	6
1.6 Manfaat Penelitian.....	6
1. Bagi Penulis.....	6
2. Bagi Dosen atau Pembimbing Akademik.....	6
3. Bagi Masyarakat Umum.....	6
4. Bagi Perusahaan Perbankan.....	6
5. Bagi Peneliti Selanjutnya.....	7
BAB 2. Tinjauan Pustaka.....	8
2.1 Penelitian Terdahulu.....	8
2.2 Landasan Teori.....	9
2.2.1 Data Mining.....	9
2. Data Understanding.....	11
3. Data Transformation.....	11
4. Data Mining.....	11
5. Model Evaluation.....	11
6. Interpretation and Visualization.....	11
7. Knowledge Utilization.....	11
2.2.2 Klasifikasi.....	11
2.2.3 Algoritma Decision Tree.....	12
1. Root Node.....	13
2. Internal Node.....	13
3. Leaf Node.....	13
2.2.4 Algoritma Decision Tree C4.5.....	14
2.2.4.1 Entropy.....	14
2.2.4.2 Information Gain.....	15
2.2.5 Customer Churn.....	16
LINK GOOGLE COLLAB.....	17

BAB 1. Pendahuluan

1.1 Judul Penelitian

Klasifikasi Churn Nasabah Menggunakan Algoritma Decision Tree C4.5 pada Dataset Bank Customer Churn

1.2 Latar Belakang

Perkembangan teknologi informasi dan digitalisasi dalam sektor perbankan menyebabkan meningkatnya jumlah data nasabah yang tersimpan setiap harinya. Data tersebut mencakup berbagai informasi penting, seperti identitas nasabah, riwayat transaksi, saldo rekening, penggunaan produk bank, hingga aktivitas layanan perbankan lainnya. Banyaknya data yang dimiliki bank dapat dimanfaatkan untuk membantu proses pengambilan keputusan, salah satunya dalam menganalisis perilaku nasabah terhadap layanan yang diberikan.

Salah satu permasalahan yang sering dihadapi oleh perusahaan perbankan adalah customer churn atau churn nasabah. Churn merupakan kondisi ketika nasabah memutuskan berhenti menggunakan layanan suatu bank atau berpindah ke layanan bank lain. Tingginya tingkat churn dapat memberikan dampak negatif bagi perusahaan, seperti menurunnya jumlah pelanggan aktif, berkurangnya pendapatan perusahaan, serta meningkatnya biaya pemasaran untuk mendapatkan nasabah baru. Oleh karena itu, mempertahankan nasabah lama menjadi hal yang sangat penting dalam menjaga kestabilan bisnis perbankan.

Dalam praktiknya, pihak bank sering mengalami kesulitan dalam mengetahui nasabah yang berpotensi melakukan churn. Hal tersebut disebabkan oleh banyaknya faktor yang mempengaruhi keputusan nasabah, seperti tingkat kepuasan layanan, usia, saldo rekening, jumlah produk yang digunakan, hingga aktivitas penggunaan layanan bank. Apabila potensi churn dapat diketahui lebih awal, maka pihak bank dapat melakukan tindakan pencegahan, seperti meningkatkan kualitas layanan, memberikan promosi, atau menawarkan program loyalitas kepada nasabah tertentu.

Pemanfaatan teknologi data mining dan machine learning dapat menjadi solusi dalam mengatasi permasalahan tersebut. Data mining merupakan proses pengolahan data untuk menemukan pola atau informasi penting dari sekumpulan data dalam jumlah besar. Salah

satu teknik dalam data mining yang sering digunakan adalah klasifikasi. Teknik klasifikasi bertujuan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan atribut yang dimiliki. Dalam penelitian ini, klasifikasi digunakan untuk menentukan apakah seorang nasabah termasuk ke dalam kategori churn atau tidak churn.

Algoritma yang digunakan dalam penelitian ini adalah Decision Tree C4.5. Algoritma Decision Tree C4.5 merupakan pengembangan dari algoritma ID3 (Iterative Dichotomiser 3) yang digunakan untuk membentuk pohon keputusan dalam proses klasifikasi data. Algoritma ini mampu menangani data numerik maupun kategorikal serta menghasilkan aturan keputusan yang mudah dipahami dan diinterpretasikan. Selain itu, Decision Tree C4.5 memiliki kemampuan dalam memilih atribut paling berpengaruh menggunakan perhitungan gain ratio, sehingga cocok digunakan dalam proses klasifikasi churn nasabah.

Penelitian ini menggunakan dataset *Bank Customer Churn* yang berisi berbagai atribut nasabah seperti Credit Score, Geography, Gender, Age, Balance, NumOfProducts, EstimatedSalary, dan atribut lainnya. Sebelum proses klasifikasi dilakukan, data terlebih dahulu melalui tahapan preprocessing untuk meningkatkan kualitas data. Tahapan preprocessing meliputi pengecekan missing value, penghapusan atribut yang tidak relevan, encoding data kategorikal, normalisasi data numerik menggunakan MinMaxScaler, serta pembagian data train dan test.

Selain itu, pada dataset ditemukan kondisi data tidak seimbang (*imbalanced data*) antara kelas churn dan tidak churn. Jumlah data nasabah yang tidak churn jauh lebih banyak dibandingkan data churn, sehingga dapat memengaruhi performa model klasifikasi. Untuk mengatasi permasalahan tersebut digunakan metode SMOTE (*Synthetic Minority Oversampling Technique*) yang diterapkan pada data training agar distribusi kelas menjadi lebih seimbang dan model dapat belajar dengan lebih baik.

Dengan demikian, penelitian ini dilakukan untuk membangun model klasifikasi churn nasabah menggunakan algoritma Decision Tree C4.5 berdasarkan dataset Bank Customer Churn. Diharapkan hasil penelitian ini dapat membantu pihak perbankan dalam memahami pola perilaku nasabah serta mendukung pengambilan keputusan dalam upaya mempertahankan loyalitas pelanggan.

1.3 Rumusan Masalah

1. Bagaimana penerapan algoritma Decision Tree C4.5 dalam mengklasifikasikan churn nasabah pada dataset Bank Customer Churn?
2. Atribut apa saja yang paling berpengaruh terhadap kemungkinan nasabah melakukan churn berdasarkan hasil klasifikasi?
3. Bagaimana pengaruh preprocessing data dan metode SMOTE terhadap proses klasifikasi churn nasabah?
4. Seberapa baik performa model Decision Tree C4.5 dalam melakukan klasifikasi churn nasabah berdasarkan data yang digunakan?

1.4 Batasan Masalah

1. Penelitian ini menggunakan data sekunder berupa Bank Customer Churn Dataset yang berisi informasi historis nasabah bank seperti Credit Score, Geography, Gender, Age, Balance, NumOfProducts, EstimatedSalary, Card Type, Point Earned, dan atribut lainnya yang relevan terhadap klasifikasi churn nasabah.
2. Target klasifikasi dalam penelitian ini adalah atribut Exited, yang digunakan untuk menentukan apakah seorang nasabah termasuk kategori churn atau tidak churn.
3. Proses analisis data dilakukan menggunakan algoritma klasifikasi Decision Tree C4.5 tanpa melakukan perbandingan performa dengan algoritma klasifikasi lainnya.
4. Tahapan preprocessing data yang dilakukan meliputi pengecekan missing value, penghapusan atribut yang tidak relevan, encoding data kategorik menggunakan Label Encoder, normalisasi data numerik menggunakan metode MinMaxScaler, serta pembagian data training dan testing.
5. Penelitian ini menggunakan metode SMOTE (*Synthetic Minority Oversampling Technique*) untuk menangani kondisi data tidak seimbang (*imbalanced data*) pada data training.
6. Evaluasi model dilakukan menggunakan data testing hasil pembagian dataset dengan rasio 80:20 untuk mengetahui performa klasifikasi model yang dibangun.
7. Penelitian ini hanya berfokus pada proses klasifikasi churn nasabah berdasarkan dataset yang digunakan dan tidak membahas implementasi sistem secara langsung pada layanan perbankan nyata.

1.5 Tujuan Penelitian

1. Membangun model klasifikasi churn nasabah menggunakan algoritma Decision Tree C4.5.
2. Mengidentifikasi atribut-atribut yang mempengaruhi kemungkinan nasabah melakukan churn.
3. Menerapkan preprocessing data dan metode SMOTE untuk meningkatkan kualitas data klasifikasi.
4. Mengetahui performa algoritma Decision Tree C4.5 dalam mengklasifikasikan churn nasabah.

1.6 Manfaat Penelitian

1. Bagi Penulis

- Menambah pengetahuan dan wawasan mengenai penerapan data mining dan machine learning menggunakan algoritma Decision Tree C4.5.
- Memberikan pengalaman dalam melakukan preprocessing data, klasifikasi, dan evaluasi model machine learning.
- Menjadi sarana penerapan ilmu yang telah dipelajari selama perkuliahan.

2. Bagi Dosen atau Pembimbing Akademik

- Menjadi referensi tambahan dalam pembelajaran terkait klasifikasi data dan data mining.
- Menjadi contoh penerapan algoritma Decision Tree C4.5 dalam studi kasus dunia perbankan.

3. Bagi Masyarakat Umum

- Memberikan pemahaman mengenai pentingnya analisis data dalam meningkatkan kualitas layanan perbankan.
- Memberikan gambaran tentang faktor-faktor yang dapat mempengaruhi loyalitas nasabah terhadap layanan bank.

4. Bagi Perusahaan Perbankan

- Membantu pihak bank dalam memahami perilaku nasabah berdasarkan data historis yang dimiliki.
- Menjadi bahan pertimbangan dalam menentukan strategi untuk mengurangi tingkat churn nasabah.

- Mendukung pengambilan keputusan berbasis data dalam meningkatkan loyalitas pelanggan.

5. Bagi Peneliti Selanjutnya

- Menjadi referensi untuk penelitian lanjutan mengenai klasifikasi churn nasabah menggunakan algoritma machine learning.
- Memberikan dasar pengembangan penelitian dengan metode klasifikasi atau teknik preprocessing lainnya.

BAB 2. Tinjauan Pustaka

2.1 Penelitian Terdahulu

Penelitian terdahulu yang digunakan dalam penelitian ini salah satunya adalah penelitian yang dilakukan oleh Wardani, Dantes, dan Indrawan (2018) dengan judul *“Prediksi Customer Churn dengan Algoritma Decision Tree C4.5 Berdasarkan Segmentasi Pelanggan pada Perusahaan Retail”*. Penelitian tersebut membahas penerapan algoritma Decision Tree C4.5 untuk melakukan prediksi customer churn pada perusahaan retail dengan menggunakan segmentasi pelanggan berbasis RFM (*Recency, Frequency, Monetary*). Data yang digunakan berasal dari data pelanggan dan data transaksi pada UD. Mawar Sari. Hasil penelitian menunjukkan bahwa algoritma Decision Tree C4.5 mampu menghasilkan performa klasifikasi yang baik pada beberapa kelas pelanggan, khususnya pada kelas *Everyday* dengan nilai *Recall* sebesar 100%, *Precision* sebesar 99,04%, dan *Accuracy* sebesar 99,04%. Selain itu, penelitian tersebut menunjukkan bahwa pelanggan dengan kelas *Dormant* memiliki potensi churn tertinggi. Kelebihan penelitian ini terletak pada penggunaan metode segmentasi pelanggan sehingga karakteristik pelanggan dapat dianalisis secara lebih detail sebelum dilakukan proses klasifikasi. Namun, penelitian ini masih memiliki keterbatasan karena dataset yang digunakan hanya berasal dari satu perusahaan retail sehingga hasil penelitian belum tentu memberikan hasil yang sama apabila diterapkan pada bidang lain. Penelitian ini dijadikan referensi karena memiliki kesamaan dalam penggunaan algoritma Decision Tree C4.5 untuk melakukan prediksi customer churn serta memberikan gambaran mengenai proses evaluasi model klasifikasi menggunakan confusion matrix.

Penelitian lainnya dilakukan oleh Sinata dkk. (2025) dengan judul *“Klasifikasi Pelanggan pada Customer Churn Prediction Models Menggunakan Decision Tree”*. Penelitian ini membahas penerapan algoritma Decision Tree C4.5 dalam proses klasifikasi pelanggan untuk memprediksi customer churn menggunakan dataset sebanyak 996 data pelanggan dengan atribut berupa jenis kelamin, usia, metode pembayaran, dan riwayat transaksi pelanggan. Hasil penelitian menunjukkan bahwa model yang dibangun mampu mengklasifikasikan pelanggan ke dalam kategori loyal dan churn dengan tingkat akurasi sebesar 98%. Selain itu, model juga memiliki nilai *Precision* sebesar 97,00% dan *Recall* sebesar 95,50% pada kelas churn sehingga menunjukkan bahwa algoritma Decision Tree C4.5 cukup efektif dalam mengidentifikasi pelanggan yang berpotensi

berhenti menggunakan layanan perusahaan. Kelebihan penelitian ini adalah penggunaan metode evaluasi yang lebih lengkap seperti *Accuracy*, *Precision*, *Recall*, dan *F1-Score* sehingga performa model dapat dianalisis secara lebih rinci. Penelitian ini juga menggunakan teknik *k-Fold Cross Validation* untuk meningkatkan keakuratan model. Akan tetapi, atribut yang digunakan dalam penelitian masih terbatas sehingga kemungkinan terdapat faktor lain yang dapat mempengaruhi customer churn namun belum dianalisis lebih lanjut. Penelitian ini dijadikan referensi karena memiliki kesamaan topik penelitian, yaitu prediksi customer churn menggunakan algoritma Decision Tree C4.5, serta memberikan gambaran mengenai proses klasifikasi pelanggan dan evaluasi performa model klasifikasi.

2.2 Landasan Teori

2.2.1 Data Mining

Data mining merupakan proses ekstraksi pengetahuan atau informasi yang bernilai dari sekumpulan data berukuran besar dan kompleks. Data mining bertujuan untuk menemukan pola, hubungan, tren, maupun informasi tersembunyi yang dapat digunakan sebagai dasar dalam pengambilan keputusan. Dalam prosesnya, data mining memanfaatkan berbagai teknik statistik, machine learning, matematika, dan kecerdasan buatan untuk menganalisis data secara sistematis.

Menurut Han, Kamber, dan Pei, data mining merupakan proses menemukan pola atau pengetahuan yang menarik dari sejumlah besar data. Sementara itu, dalam Buku Ajar Data Mining dijelaskan bahwa data mining adalah proses ekstraksi informasi berharga dari sekumpulan data yang besar dan kompleks sehingga dapat memberikan wawasan yang lebih mendalam dan bernilai.

Tujuan utama data mining adalah menemukan pola atau hubungan tersembunyi dalam data yang sulit dikenali secara langsung. Selain itu, data mining juga digunakan untuk melakukan prediksi, klasifikasi, segmentasi pelanggan, analisis asosiasi, deteksi anomali, serta membantu pengambilan keputusan.

Beberapa tujuan khusus data mining antara lain:


1. Mengidentifikasi pola atau hubungan antar data
2. Melakukan prediksi terhadap suatu kondisi
3. Mengelompokkan data ke dalam kategori tertentu

4. Melakukan segmentasi pelanggan
5. Mengidentifikasi anomali data
6. Mendukung proses pengambilan keputusan
7. Menemukan pengetahuan baru dari data historis

Tahapan data mining atau Knowledge Discovery in Database (KDD) terdiri dari beberapa proses, yaitu:

1. Selection and Preprocessing
2. Data Understanding
3. Data Transformation
4. Data Mining
5. Model Evaluation
6. Interpretation and Visualization
7. Knowledge Utilization

Gambar 2.1 Tahapan Data Mining / KDD Process



Penjelasan tahapan data mining:

1. Selection and Preprocessing

Tahap pemilihan data yang relevan dari berbagai sumber data serta melakukan proses awal seperti pembersihan data dan penghapusan data yang tidak diperlukan.

2. Data Understanding

Tahap memahami karakteristik dataset melalui analisis awal, identifikasi missing value, distribusi data, dan hubungan antar variabel.

3. Data Transformation

Tahap mengubah data ke dalam format yang sesuai untuk proses analisis, seperti normalisasi, encoding data kategorikal, dan reduksi atribut.

4. Data Mining

Tahap utama penerapan algoritma tertentu untuk menemukan pola atau membangun model prediksi.

5. Model Evaluation

Tahap evaluasi model untuk mengetahui tingkat performa model yang telah dibangun.

6. Interpretation and Visualization

Tahap interpretasi hasil analisis dan penyajian hasil dalam bentuk visualisasi.

7. Knowledge Utilization

Tahap penggunaan pengetahuan yang diperoleh untuk mendukung pengambilan keputusan.

2.2.2 Klasifikasi

Klasifikasi merupakan salah satu teknik dalam data mining yang digunakan untuk mengelompokkan data ke dalam kelas atau kategori tertentu berdasarkan atribut yang dimiliki. Proses klasifikasi dilakukan dengan membangun model menggunakan data training yang telah memiliki label kelas, kemudian model tersebut digunakan untuk memprediksi kelas pada data baru.

Klasifikasi termasuk metode supervised learning karena menggunakan data yang telah diketahui label atau targetnya. Dalam proses klasifikasi, algoritma akan mempelajari pola dari data training untuk menghasilkan model klasifikasi yang dapat digunakan dalam proses prediksi.

Fungsi klasifikasi dalam data mining antara lain:


1. Mengelompokkan data ke dalam kategori tertentu
2. Membantu proses prediksi
3. Mendukung pengambilan keputusan
4. Mengidentifikasi pola data
5. Mempermudah analisis data

Penerapan klasifikasi banyak digunakan dalam berbagai bidang seperti:

- Kesehatan untuk prediksi penyakit
- Pendidikan untuk prediksi kelulusan mahasiswa
- Perbankan untuk prediksi customer churn
- Bisnis untuk klasifikasi pelanggan
- Keamanan untuk deteksi spam atau penipuan

Dalam penelitian ini, klasifikasi digunakan untuk memprediksi apakah nasabah bank termasuk kategori churn atau tidak churn berdasarkan atribut pelanggan yang tersedia.

Gambar 2.2 Ilustrasi Proses Klasifikasi



Pada proses klasifikasi, data training digunakan untuk membangun model klasifikasi, kemudian model tersebut digunakan untuk melakukan prediksi terhadap data testing.

2.2.3 Algoritma Decision Tree

Decision Tree atau pohon keputusan merupakan metode klasifikasi yang merepresentasikan proses pengambilan keputusan dalam bentuk struktur pohon.

Metode ini digunakan untuk membentuk aturan keputusan berdasarkan atribut yang dimiliki data.

Decision Tree termasuk salah satu metode klasifikasi yang populer karena mudah dipahami dan divisualisasikan. Hasil klasifikasi dari Decision Tree berbentuk aturan keputusan yang sederhana sehingga memudahkan pengguna dalam memahami proses klasifikasi.

Struktur Decision Tree terdiri dari:

1. **Root Node**

Root node merupakan node awal yang menjadi pusat pembentukan pohon keputusan.


2. **Internal Node**

Internal node merupakan node percabangan yang menunjukkan pengujian terhadap atribut tertentu.

3. **Leaf Node**

Leaf node merupakan node akhir yang menunjukkan hasil keputusan atau kelas data.

Gambar 2.3 Struktur Decision Tree



Pada struktur pohon keputusan, root node menjadi titik awal pengambilan keputusan, kemudian data akan mengikuti cabang berdasarkan kondisi tertentu hingga mencapai leaf node yang menunjukkan hasil klasifikasi.

Decision Tree memiliki beberapa kelebihan, antara lain:

1. Mudah dipahami dan diinterpretasikan
2. Dapat menangani data numerik dan kategorikal
3. Proses klasifikasi relatif cepat
4. Dapat divisualisasikan dalam bentuk pohon keputusan
5. Memiliki tingkat akurasi yang baik
6. Tidak memerlukan proses normalisasi data yang kompleks

Namun, Decision Tree juga memiliki beberapa kekurangan, seperti:

1. Rentan mengalami overfitting
2. Struktur pohon dapat menjadi sangat kompleks
3. Sensitif terhadap perubahan data

2.2.4 Algoritma Decision Tree C4.5

Algoritma C4.5 merupakan pengembangan dari algoritma ID3 yang diperkenalkan oleh J. Ross Quinlan. Algoritma ini digunakan untuk membentuk pohon keputusan berdasarkan nilai entropy dan information gain dari setiap atribut.

Algoritma C4.5 bekerja dengan memilih atribut terbaik yang memiliki nilai gain tertinggi untuk dijadikan root node. Proses tersebut dilakukan secara berulang hingga seluruh data berhasil diklasifikasikan.

Tahapan kerja algoritma C4.5 meliputi:

1. Menghitung nilai entropy
2. Menghitung nilai information gain
3. Menentukan atribut dengan gain tertinggi
4. Membentuk pohon keputusan
5. Melakukan proses klasifikasi

2.2.4.1 Entropy

Entropy digunakan untuk mengukur tingkat ketidakpastian suatu data. Semakin besar nilai entropy, maka semakin tinggi tingkat ketidakpastian data.

Rumus entropy:

$$H = - \sum_{i=1}^n p_i \log_2(p_i)$$

Keterangan:

- S = himpunan kasus
- p_i = probabilitas kelas ke- i

2.2.4.2 Information Gain

Information gain digunakan untuk menentukan atribut terbaik dalam pembentukan pohon keputusan. Atribut dengan nilai gain tertinggi akan dipilih sebagai node utama.

Rumus information gain:

$$\text{Information Gain}(S,a) = \text{Entropy}(S) - \sum_{v \in \text{values}(a)} \frac{|S_v|}{|S|} \text{Entropy}(S_v)$$

Keterangan:

- S = himpunan kasus
- A = atribut
- S_i = subset kasus

2.2.5 Customer Churn

Customer churn merupakan kondisi ketika pelanggan berhenti menggunakan layanan atau produk dari suatu perusahaan dalam periode tertentu. Dalam dunia perbankan, churn nasabah dapat menyebabkan penurunan keuntungan dan loyalitas pelanggan. Customer churn menjadi salah satu permasalahan penting bagi perusahaan karena kehilangan pelanggan dapat berdampak pada penurunan pendapatan perusahaan. Oleh karena itu, perusahaan perlu melakukan prediksi churn untuk mempertahankan pelanggan.

Beberapa faktor yang mempengaruhi churn nasabah antara lain:

1. Umur pelanggan
2. Saldo rekening
3. Jumlah produk bank yang digunakan
4. Aktivitas transaksi
5. Kepemilikan kartu kredit
6. Status keaktifan nasabah
7. Kepuasan pelanggan

Dampak customer churn bagi perusahaan antara lain:

1. Penurunan keuntungan perusahaan
2. Berkurangnya loyalitas pelanggan
3. Meningkatnya biaya pemasaran
4. Menurunnya stabilitas bisnis

Prediksi customer churn sangat penting dilakukan karena dapat membantu perusahaan dalam:

1. Mempertahankan pelanggan
2. Menentukan strategi bisnis
3. Mengurangi tingkat kehilangan nasabah
4. Meningkatkan loyalitas pelanggan
5. Mendukung pengambilan keputusan bisnis

LINK GOOGLE COLLAB

 A12_TugasAkhir.ipynb